따라하며 배우는

빅데이터 분석

Big Data Analytics

박동규 지음

CHAPTER

01 빅데이터로 통하는 세상

CONTENTS

1.1 데이터와 정보, 그리고 지식
1.2 디지털 세상과 정보의 표현
1.3 디지털 데이터의 용량
1.4 정보의 원천 빅데이터
1.5 스프레드시트와 데이터베이스
1.6 데이터 분석 활용사례
1.7 데이터 중심의 과학
1.8 데이터 과학이란
1.9 데이터 과학자를 위한 다양한 플랫폼
1.10 데이터 마켓과 열린 데이터
1.11 데이터 분석의 단계
LAB 1-1 구글 트렌드 살펴보기
LAB 1-2 빅데이터의 원천인 소셜 미디어

1.1 데이터와 정보, 그리고 지식

- **데이터**data란 **현실 세계에서 측정하고 수집한 사실이나 값**을 말하며
- **정보**information는 **어떠한 목적이나 의도에 맞게 데이터를 가공 처리한 것**을 말함
- 우리가 의사결정을 내리기 위해서는 단순히 수집한 원시 데이터만으로는 부족하며, 원시 데이터에 의미를 부여해야만 하는데 이와 같이 **가공된 데이터가 정보**가 됨

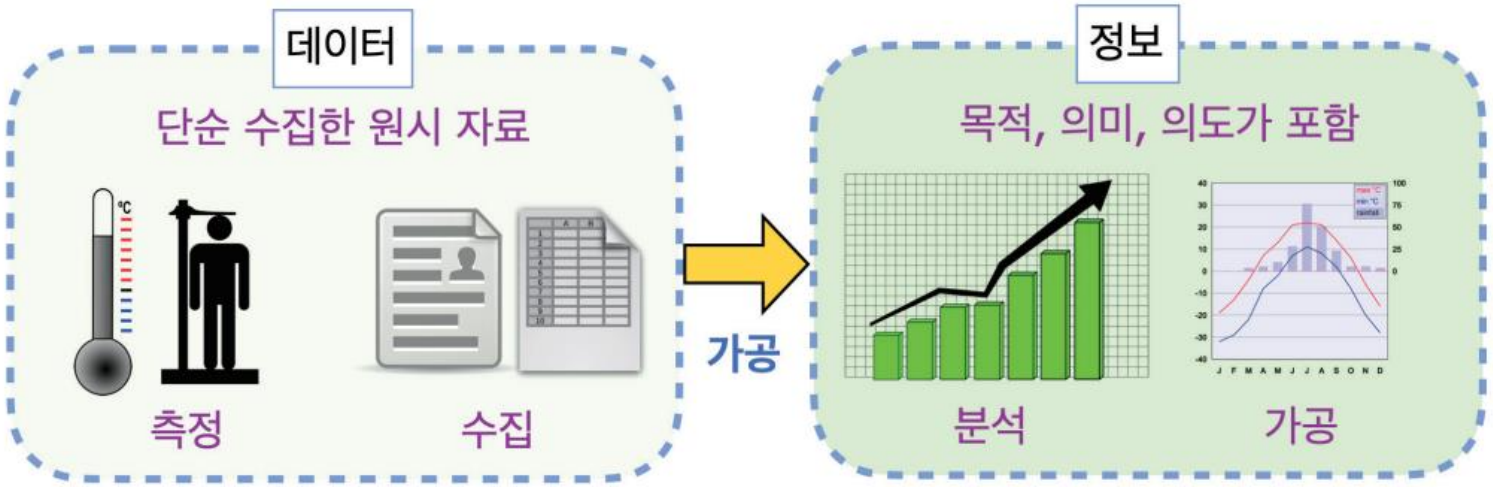

1.3 디지털 데이터의 용량

- 컴퓨터와 같은 정보 기기에서 정보의 표현에 사용되는 비트와 바이트, 그리고 그 이상의 데이터 용량은 다음과 같은 이름과 기호로 표기

이름	기호	설명
1 비트	bit	0 또는 1
1 바이트	byte	8 bit
1 킬로바이트	KB	1,024 byte (= 2^{10} byte)
1 메가바이트	MB	1,024 KB (= 2^{10} KB = 2^{20} byte)
1 기가바이트	GB	1,024 MB (= 2^{10} MB = 2^{30} byte)
1 테라바이트	TB	1,024 GB (= 2^{10} GB = 2^{40} byte)
1 페타바이트	PB	1,024 TB (= 2^{10} TB = 2^{50} byte)
1 엑사바이트	EB	1,024 PB (= 2^{10} PB = 2^{60} byte)
1 제타바이트	ZB	1,024 EB (= 2^{10} EB = 2^{70} byte)

1.3 디지털 데이터의 용량

- 이 밖에도 제타바이트의 1,024배인 요타바이트, 요타바이트의 1,024배인 브론토바이트라는 거대한 단위도 존재
- 데이터의 용량이 실제로 어느 정도의 정보량을 표현하는지는 다음 표로 설명할 수 있음

데이터 용량	정보의 양
1 바이트	영문자 한 자에 해당함. 전 세계 문자를 모두 표현하기 위한 코드인 유니코드는 2 바이트를 사용함
1 킬로바이트	약 1,000자의 영문자
1 메가바이트	약 1,000,000자의 영문자로 400페이지 책 한 권 분량의 정보
1 기가바이트	230곡가량의 노래
1 테라바이트	31만 장의 사진, 혹은 500시간 분량의 동영상에 해당함
1 페타바이트	5천억 페이지의 표준 입력 텍스트, 3억 1천만 장가량의 사진 영화 아바타의 그래픽 렌더링에서는 약 1 페타바이트가 사용됨
1 엑사바이트	1,100만 개의 4K 동영상 지금까지 인류가 생성한 모든 말을 저장할 경우 5 엑사바이트에 해당함
1 제타바이트	DVD 250억 장의 데이터 양 유튜브에서 매달 시청되는 동영상 용량은 약 1.14 제타바이트에 해당함

1.4 정보의 원천 빅데이터

- **빅데이터**big data는 기존 데이터베이스 관리 도구의 능력을 넘어서는 대량의 정형·비정형 데이터 집합으로부터 가치를 추출하고 결과를 분석하는 기술

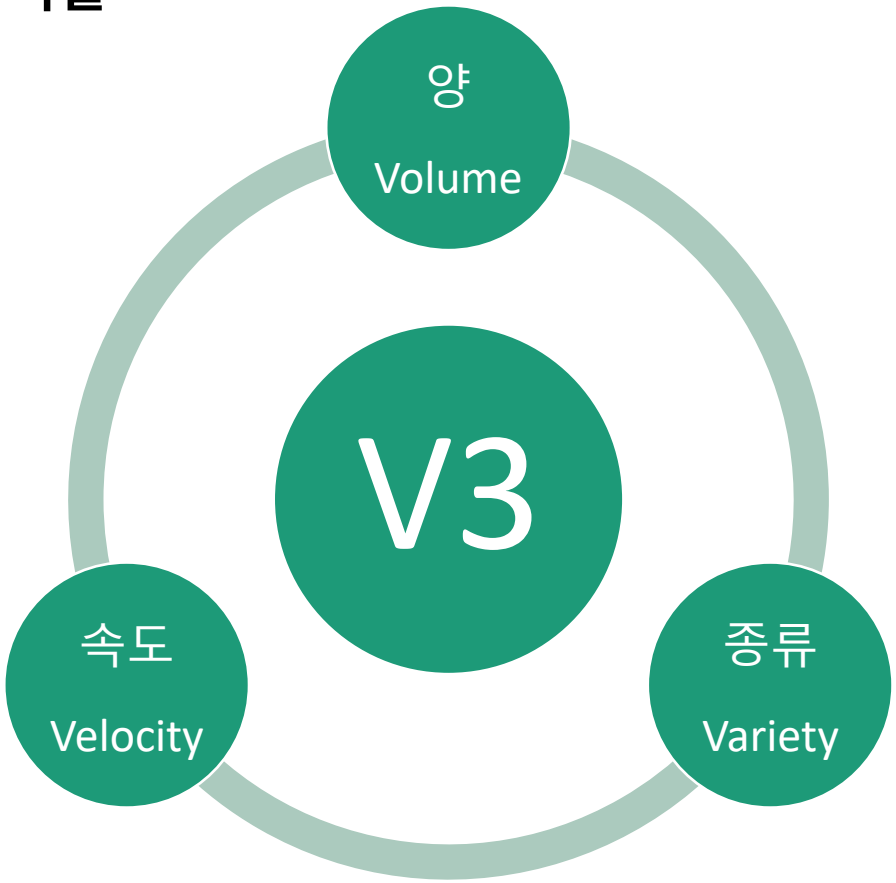

4-2. 정보의 원천 빅데이터

- 빅데이터의 대표적인 특징인 양, 속도, 종류

양 (Volume)	빅데이터는 일반적인 컴퓨터에서 처리할 수 있는 메가바이트나 기가바이트 단위의 데이터를 넘어서는 테라바이트~엑사바이트 이상의 데이터를 저장하여 분석하고 가공해야 한다. 페타바이트는 250 바이트 크기의 데이터이며, 엑사바이트는 260 바이트 크기의 데이터이다. 이 이상의 데이터는 엄청난 물리적 데이터 크기로 인하여 현재의 컴퓨터 기술로도 이를 분석 및 처리하는 데 어려움이 따른다.
속도 (Velocity)	사물인터넷을 비롯한 센서와 다양한 모바일 기기, 소셜 미디어 등으로부터 발생되는 매우 빠른 속도의 실시간적인 데이터 증가를 그 특징으로 볼 수 있다.
종류 (Variety)	사용자의 컴퓨터나 스마트폰에서 사용자가 접속하여 종료할 때까지의 모든 활동 기록을 로그 기록이라 하는데 이러한 로그 기록, 소셜 미디어 사용 내역, 실시간 시청 기록 등의 다양한 기기와 매체를 통해서 데이터가 축적되므로 텍스트 정보 이외에도 멀티미디어 정보와 같은 비정형화된 데이터가 많은 부분을 차지하는 특징이 있다.

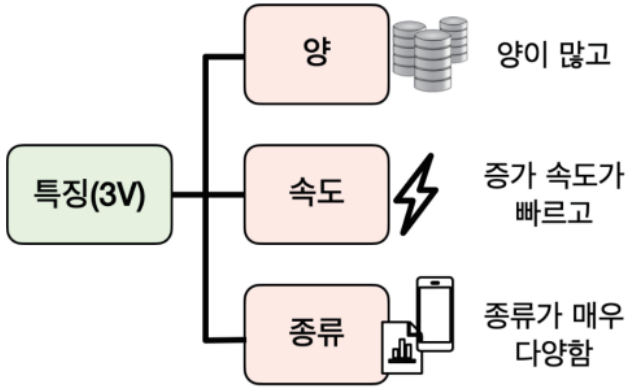

빅데이터의 대표적인 특징들

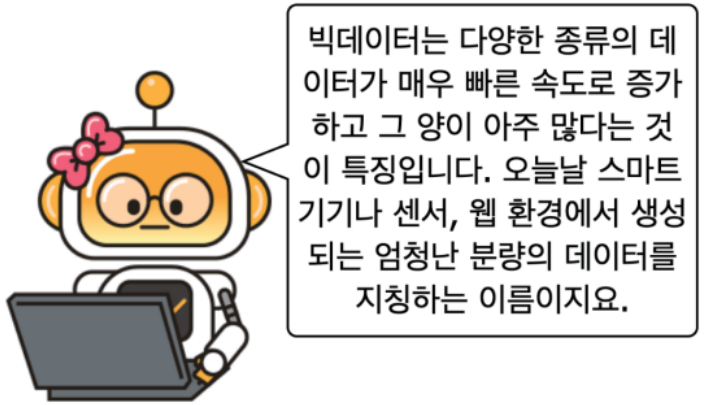

1.4 정보의 원천 빅데이터

- 데이터 인프라에 해당하는 광대역 네트워크, 클라우드 서비스, 사물인터넷, 소셜미디어로부터 획득한 정형/비정형 데이터가 빅데이터의 핵심이 되며 이 데이터를 인공지능 모델과 같은 곳에서 활용하여 경제적 가치를 창출하거나 사회적 문제를 해결할 수 있을 것

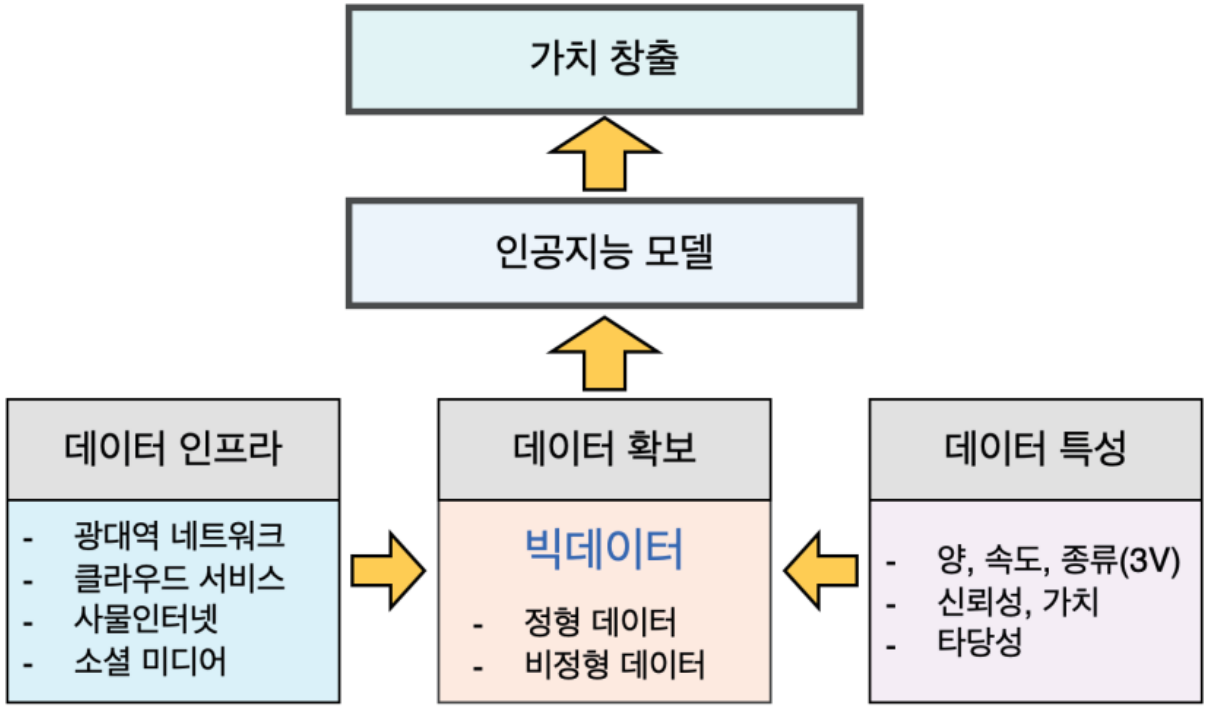

1.4 정보의 원천 빅데이터

NOTE 빅데이터와 금융 범죄 방지를 위한 노력

빅데이터의 가치는 **이전에는 관리되지 않던 새로운 데이터를 수집하고 분석함으로써 새로운 가치를 창출**하는 데 큰 의의가 있다. 예를 들어 온라인 쇼핑몰이나 검색 사이트에서는 고객의 다양한 로그와 검색 결과 등과 같은 빅데이터를 통해서 의미 있는 정보를 실시간으로 도출할 수 있다.

이러한 분석 결과는 이상 감지, 트렌드 파악, 가까운 미래의 예측, 의사결정 등에 다양하게 활용될 수 있다. 예를 들어, 우리나라의 경우 국세청에서 운영하는 금융정보분석원의 정보시스템은 금융 회사들이 보고하는 **빅데이터**를 바탕으로 **기계학습**을 통해 금융 범죄를 찾아낸다. 이 시스템은 자금 세탁 범죄와 관련된 금융 거래 정보를 분석하여 법집행기관에 제공하는 자금세탁 방지 시스템으로서 의심 거래 보고, 고액 현금 거래 보고를 바탕으로 운영된다.

금융 기관에서 금융정보분석원으로 보고되는 상세한 정보는 아래와 같다.

1) **의심 거래 보고**: 금융 회사에서 금융 거래와 관련하여 자금 세탁이 의심되는 합당한 근거가 있는 경우 금융 정보 분석원에 보고하는 정보

2) **고액 현금 거래 보고**: 금융 회사에서 동일인 명의로 1거래일간 이루어지는 현금 거래가 1천만 원 이상인 경우 금융 정보 분석원에 보고하는 정보

1.5 스프레드시트와 데이터베이스

- 데이터 분석 전문가들이 다루는 데이터는 이와 같이 표 형식의 규격화된 데이터뿐만이 아니라 비규격화된 데이터들도 많음
  - 이러한 데이터는 정형 데이터, 비정형 데이터, 반정형 데이터로 구분

1.5 스프레드시트와 데이터베이스

정형 데이터

- **정형 데이터**structured data는 데이터베이스의 일정한 형식이나 정해진 규칙에 맞게 저장된 데이터
- 아래의 표를 보면 Gender라는 **컬럼(열)**column이 있는데 여기서 male, female이라는 값이 들어간다면 누가 봐도 그 값은 남자, 여자라는 것을 쉽게 인식할 수 있고, Age에 23 혹은 25와 같은 숫자가 들어가도 사람들은 쉽게 그 값을 인식할 수 있음
- 이와 같이 정형 데이터는 값이 나타내는 의미를 파악하기 쉽고, 규칙적인 값으로 이루어진 데이터임

열에는 데이터의 속성이 표시됨 | 수치 데이터 | 수치값의 합 | 수치값의 평균

학번	이름	Gender	Age	역사	국어	수학	과학	영어	합계	평균
221101	홍길동	male	23	89	96	90	93	87	366	73.2
221102	홍길순	female	25	78	76	94	67	98	335	67
221103	박동민	male	36	56	88	67	98	69	322	64
221104	강지안	male	35	98	93	89	90	87	359	71.8
221105	강이안	female	31	65	78	90	96	89	353	70.6
221106	박동윤	male	45	90	92	69	88	86	335	67
221107	강민영	male	32	79	87	87	95	89	358	71.6
221108	김수성	male	24	96	67	89	87	75	318	63.6

1.5 스프레드시트와 데이터베이스

비정형 데이터

- **비정형 데이터**unstructured data는 정해진 규칙이 없어서 값의 의미를 쉽게 파악하기 힘든 형태의 데이터
- 흔히 텍스트, 음성, 영상과 같은 데이터가 비정형 데이터 범위에 속함
- 유튜브에 업로드된 동영상이 비정형 데이터의 대표적인 경우인데, 동영상의 제목과 설명, 영상 자체의 내용은 일정한 규칙이 없어서 그 의미 파악이 힘듦
- 지금 이 순간에도 매우 빠르게 만들어지고 있는 비정형 데이터는 정형 데이터에 비하여 많이 활용되지 못했는데, 최근에는 인공지능 기술에 기반한 빅데이터 분석 기술의 발전으로 인하여 의미를 분석하기 힘들었던 대용량의 비정형 데이터를 분석함으로써 새로운 인사이트를 얻고 있음

1.5 스프레드시트와 데이터베이스

반정형 데이터

- **반정형 데이터**semi-structured data는 **관계형 데이터베이스나 다른 형태의 데이터 테이블과 연결된 정형 구조의 데이터 모델을 준수하지 않는 정형 데이터의 한 형태**
- 데이터 모델이 따로 없기는 하지만 비정형 데이터와는 달리 데이터 내에서 개별적인 고유의 특징을 식별하는 **태그**가 포함되어 있다는 점이 반정형 데이터의 특징

1.6 데이터 분석 활용사례

- 오늘날 우리가 살아가는 세상은 많은 데이터들이 빠르게 생성되고, 처리되며, 저장되고 있음
- 많은 데이터를 수집하여 이를 효과적으로 활용하는 사례로는 다음과 같은 것이 있음

[사례 1: 교통 빅데이터 분석과 교통 혼잡 지도]

국토교통부는 2013년 **교통 빅데이터 분석·처리 기술을 이용한 교통 혼잡 지도를 개발**했다. 혼잡 지도는 2013년 9월 한 달간 약 6억개의 내비게이션 이용 차량 이동 궤적을 25만 개 도로 구간에 대하여 분석하였다. 이 데이터는 도로·교차로·행정 구역별로 각각 구현하여 특정 지역별로 특정 기간에 발생하는 혼잡 강도를 파악하였다. 이 교통 혼잡 지도 시스템은 내비게이션 데이터와 도로 네트워크 자료인 빅 데이터베이스 시스템, 혼잡 여부를 판단하고 각종 지표를 생성하는 교통 혼잡 분석 시스템, 분석 결과를 지도에 표출하는 지리 정보 시스템 기반 표출 시스템으로 구성되어 있다. 교통 혼잡 지도를 분석한 결과, 광역자치단체 단위로 보면 주중에 대도시의 혼잡도가 높았으며 경상남북도, 충청남북도, 강원도의 경우 주중보다 주말의 교통 혼잡이 더 높은 것으로 나타났다. 교통 혼잡 지도는 전국 도로· 도시별 교통망 성능 평가, 교통 수요 관리, 대중 교통 활성화, 차량 이동량 등의 지속 가능한 교통 정책 수립에도 활용될 예정이다.

1.6 데이터 분석 활용사례

[사례 2: 고객 통합 관리 시스템]

LG, SK, 삼성전자 등은 최근 빅데이터 기반의 **고객 소리 통합 관리 시스템**을 개발하였다. 이 시스템은 주요 인터넷 사이트나 게시판에 게시된 수많은 자사 제품 관련 글을 빅데이터 플랫폼으로 수집·분류·분석해서 고객의 불만을 사전에 탐지하여 고객 불만의 원인이 무엇인지, 어느 지역에서 주로 발생하는지 등을 상세히 분석할 수 있으며, 앞으로 불만 사항이 얼마나, 어떻게 확대될 것인지 등을 예측할 수 있다.

[사례 3: 미국 정부의 탈세 방지 시스템]

미국 정부는 탈세를 방지하기 위하여 탈세 의심 대상자의 현재 이상 징후와 과거의 행동 정보 분석을 통한 예측 모델링을 실시하였다. 이런 방식으로 사기 패턴과 유사한 행동을 검출하였는데, 이를 위하여 소셜 네트워크 분석을 통해 계좌, 주소, 전화번호, 납세자 간의 연관 관계까지 분석하는 지능적인 범죄 네트워크 발굴 및 감시 시스템을 개발하였다. 이러한 데이터베이스를 구축하고 데이터를 분석하고 보고하는 시스템을 통합해서 다양한 빅데이터 분석을 실시하였는데, 이를 통하여 연간 3,450억 달러에 달하는 세금 누락 및 불필요한 세금 환급을 절감하고 탈세자 수를 줄일 수 있었다.

1.6 데이터 분석 활용사례

[사례 4: 축구 기술의 선진화를 이룬 EPTS]

EPTS란 Electronic Performance and Tracking System의 약자로 **생물체의 활동을 전자적으로 모니터링하고 추적하는 시스템**이다. 이런 시스템은 다양한 분야에서 사용될 수 있지만, 특히 스포츠 선수들의 활동을 과학적으로 분석하고 향상시키기 위해 많이 사용된다. EPTS는 선수들의 움직임, 속도, 거리, 심박수 등을 실시간으로 측정하고 분석함으로써, 훈련과 경기의 효율성을 높이는 데 도움을 준다.

2023년 카타르 월드컵 당시에 사용된 EPTS는 팀 코치, 의료진, 분석가들에게 선수들의 실시간 활동 데이터를 제공하였다. 팀 코치는 이를 바탕으로 경기 전략을 수립하고, 선수의 건강 상태를 모니터링하며, 개인별 맞춤 훈련을 지원하는 데 다음과 같은 도움을 주었다.

EPTS 데이터 모니터링 시스템

- **실시간 성능 추적:** EPTS는 GPS 및 다양한 센서를 통해 선수들의 위치, 속도, 가속도 등을 실시간으로 추적했다. 이를 통해 코치와 분석가들은 선수들의 움직임 패턴, 경기 중 노력의 정도, 포지셔닝 등을 분석할 수 있었다.
- **건강 및 체력 모니터링:** 심박수 모니터, 체온 센서 등을 통해 선수들의 체력 상태와 건강을 모니터링했다. 이 정보는 선수가 최적의 상태로 경기에 임할 수 있도록 하고, 부상 위험을 최소화하는 데 중요한 역할을 했다.
- **데이터 기반 의사 결정 지원:** 수집된 데이터는 경기 전략 수립, 선수 교체 타이밍 결정, 맞춤형 훈련 프로그램 개발 등에 활용되었다. 데이터 기반 접근 방식은 팀의 성능을 최적화하고 경쟁력을 높이는 데 기여했다.

이러한 기술의 발전은 향후 스포츠 이벤트에서도 계속해서 중요한 역할을 할 것으로 기대된다.

운동 선수의 활동을
모니터링 하는 센서와 조끼

1.8 데이터 과학이란

- **데이터 과학**은 다음 그림과 같이 데이터의 구조를 파악하고 이를 분석하는 적절한 알고리즘을 설계하는 것
- 이를 위하여 프로그래밍이라는 도구를 사용할 것이며, 데이터 과학의 최종 목표는 **데이터의 효율적인 분석을 통해 문제해결을 위한 지식을 쌓아가는 것**

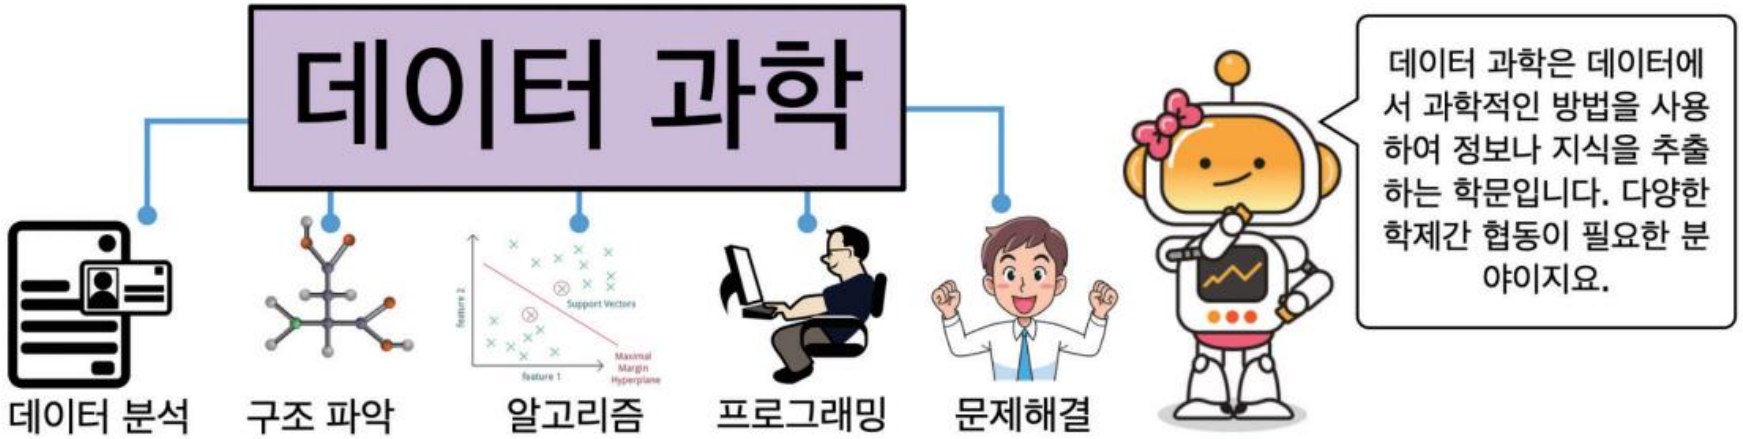

1.8 데이터 과학이란

- **데이터 과학**data science은 **데이터에서 과학적 방법으로 정보나 지식을 추출하는 학문**
- 데이터 과학은 대표적인 **학제**inter-disciplinary 연구 분야

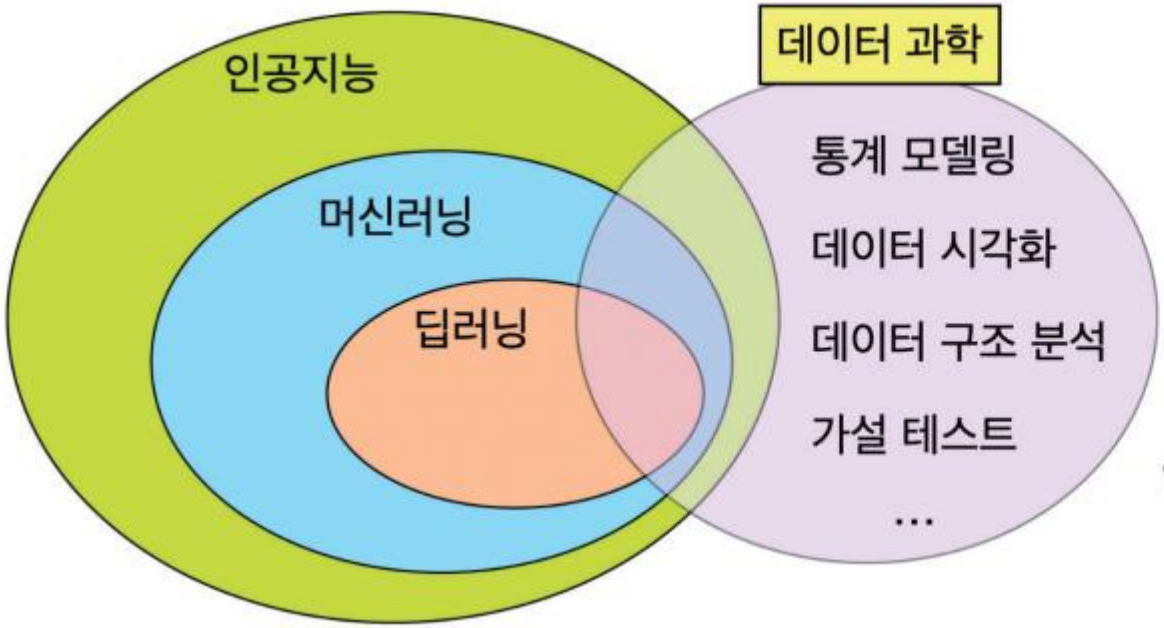

1.8 데이터 과학이란

- 인공지능 연구에서 매우 중요한 부분을 차지하는 것이 **데이터의 품질**
- 아무리 좋은 머신러닝과 딥러닝 알고리즘이 있다고 하더라도 이 알고리즘을 학습시키는 데이터의 품질이 나쁠 경우 좋은 알고리즘은 그 성능을 제대로 발휘할 수가 없음
- 데이터가 정확하지 않거나, 분석할 수 없는 형태이거나, 누락값이 많거나, 중의적이거나 또는 이미 유효기간이 지난 데이터가 대부분이라면 제 아무리 많은 데이터를 보유하고 있다 해도 활용가치는 거의 없음
- 데이터 과학에서 가장 기본이 되는 1차 데이터를 **원천 데이터**라고도 하는데 거의 모든 원천 데이터는 곧바로 활용하기에 부족함
- 그렇기 때문에 원천 데이터를 단순히 수집하여 바로 데이터 시스템에 적재해서는 안되며, 적재 이전에 일련의 정제 및 변환 작업을 거쳐야 함(데이터 통합 및 정제)

1.8 데이터 과학이란

- **데이터 마이닝**data mining이란 **대규모로 저장된 데이터 안에서 체계적이고 자동적으로 통계적 규칙이나 패턴을 분석하여 가치 있는 정보를 추출하는 과정**
- 데이터 과학과 데이터 마이닝 모두 데이터를 이용하여 의미 있는 정보를 추출한다는 공통점이 있음
- 데이터 중심의 과학의 의의

  - **새로운 패턴의 발견:** 대규모 데이터 분석을 통해 과학자들은 예상치 못한 패턴이나 상관 관계를 발견할 수 있으며, 이러한 발견은 새로운 과학적 발견으로 이어질 수 있다.
  - **이론 검증 및 정밀화:** 기존의 과학 이론이나 모델을 대량의 데이터와 비교함으로써 이론의 정확성을 검증하고, 필요한 경우 수정하거나 정밀화할 수 있다.
  - **복잡한 시스템의 이해:** 기후 변화, 인간의 유전학, 사회 경제적 현상과 같이 매우 복잡한 시스템을 데이터를 통해 분석함으로써 보다 깊이 이해할 수 있다.
  - **예측 모델링의 개선:** 대규모 데이터를 활용하여 더 정확한 예측 모델을 개발할 수 있다. 이는 과학뿐만 아니라 의료, 금융, 환경 관리 등 다양한 분야에서 응용될 수 있다.
  - **과학적 방법론의 확장:** 데이터 중심의 과학은 기존의 실험, 관찰, 이론 구축에 더해, 데이터 분석과 컴퓨터 모델링을 포함하는 현대적 과학적 방법론으로 발전하고 있다.

1.8 데이터 과학이란

- 이와 같이 데이터 중심의 과학은 정보 기술의 발달과 더불어 더욱 중요해지고 있으며, 과학 연구의 패러다임을 변화시키고 있음
- 과학자들은 이를 통하여 현대의 과학적 발견은 가속화될 것이며, 새로운 지식의 창출도 이루어 질 것으로 예상하고 있음

NOTE 자연어 처리와 빅데이터

자연어 처리natural language processing란 인간이 발화하는 언어 현상을 기계적으로 분석하여, 컴퓨터가 이해할 수 있는 형태로 만드는 여러가지 기술을 일컫는 용어이다. 인간의 언어를 컴퓨터가 이해할 수 있도록 하기 위해서는 방대한 텍스트를 수집하고 전처리 한 후 가공하는 절차가 필요하다. 인간이 사용하는 단어 중에서 "사과"라는 단어는 "**사과**는 맛있어~"라는 문장에서 사용될 때와 "어제 일은 진심으로 **사과**할게."라는 문장에서 사용될 때 그 의미는 완전히 다르다.

과거 1950년대에 인간의 언어 현상을 설명하는 법칙을 만들어 외국어 번역 시스템을 만들고자 하는 시도가 이루어졌으나 엄청난 연구비를 지출하고 10년간이나 연구를 수행하였으나 큰 진전을 보지 못한 사례가 있다. 최근 인간의 방대한 언어 사용에 대한 데이터베이스가 구축되고 이를 학습한 인공지능 알고리즘의 비약적인 발전으로 인하여 ChatGPT와 같은 효율적인 자연어 처리 시스템이 등장하고 있다.

1.9 데이터 과학자를 위한 다양한 플랫폼

- 데이터 분석을 도와주는 협업 플랫폼인 **캐글**kaggle 웹사이트의 주소

https://www.kaggle.com/

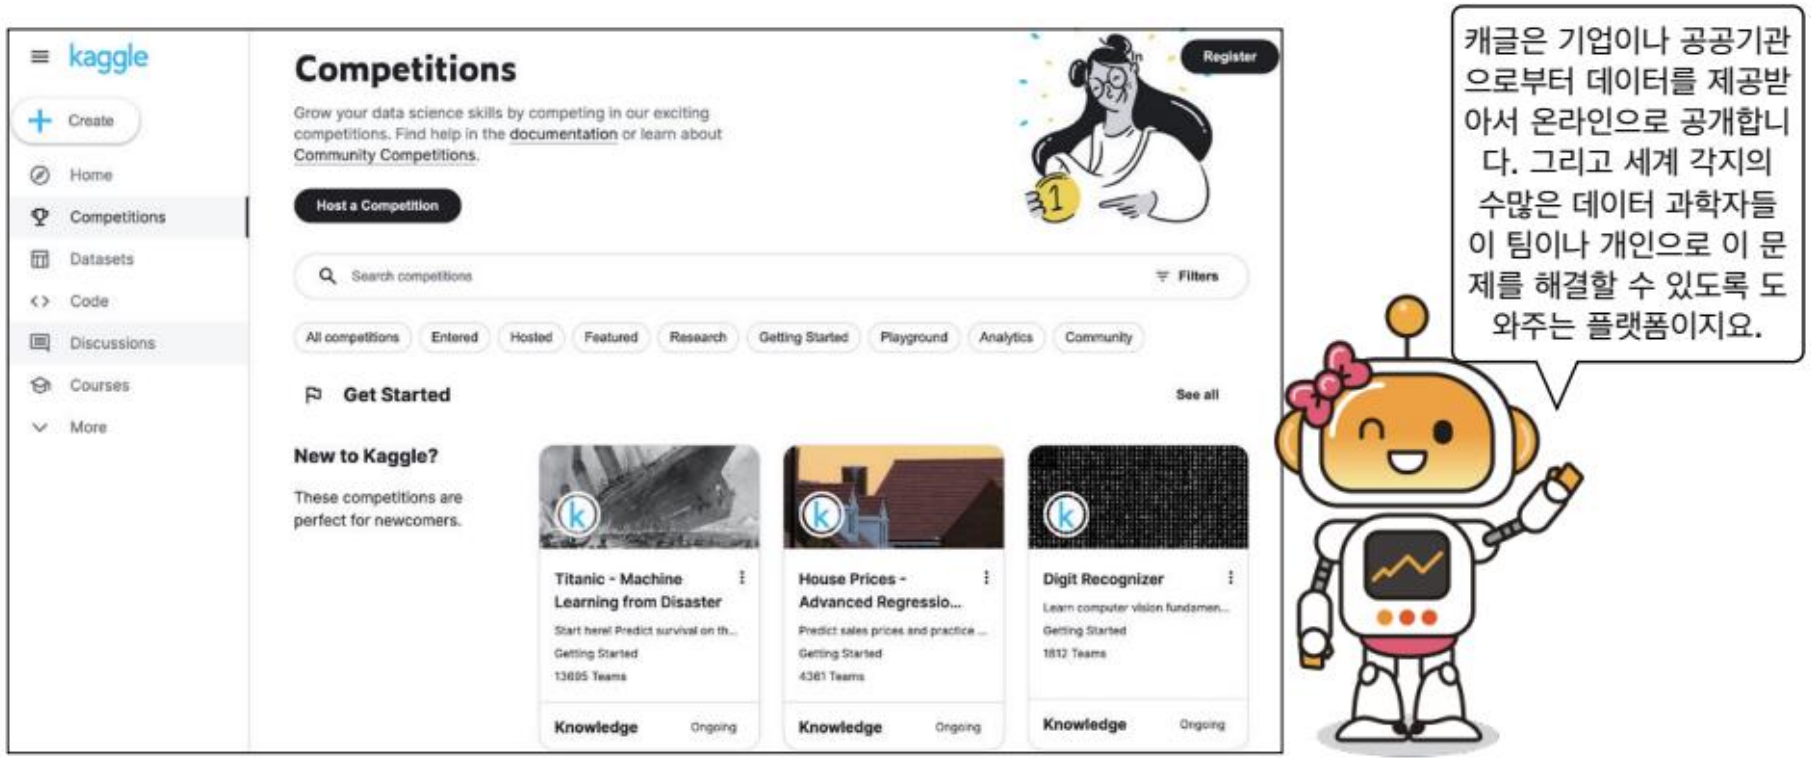

1.9 데이터 과학자를 위한 다양한 플랫폼

- 캐글에 접속한 다음 **Competitions** 메뉴를 살펴보면 그림과 같이 초보자를 위한 타이타닉 생존자를 예측하는 간단한 예제와 더불어 많은 경진대회가 상금과 함께 개최되고 있음
- 또한 캐글의 **Datasets** 메뉴에는 여러 기업이나 기관에서 공개한 풍부한 데이터 집합이 있으며 이 데이터의 분석 목표를 다음과 같이 명시하여 제공하고 있음

- 통신사에서 축적한 고객의 정보를 분석하여 주의 깊게 살펴야 할 고객 정보를 찾아내는 고객 행동 예측 분석

1.9 데이터 과학자를 위한 다양한 플랫폼

- 코로나19 환자와 정상인의 가슴 X-선 사진을 이용하여 코로나 환자를 진단

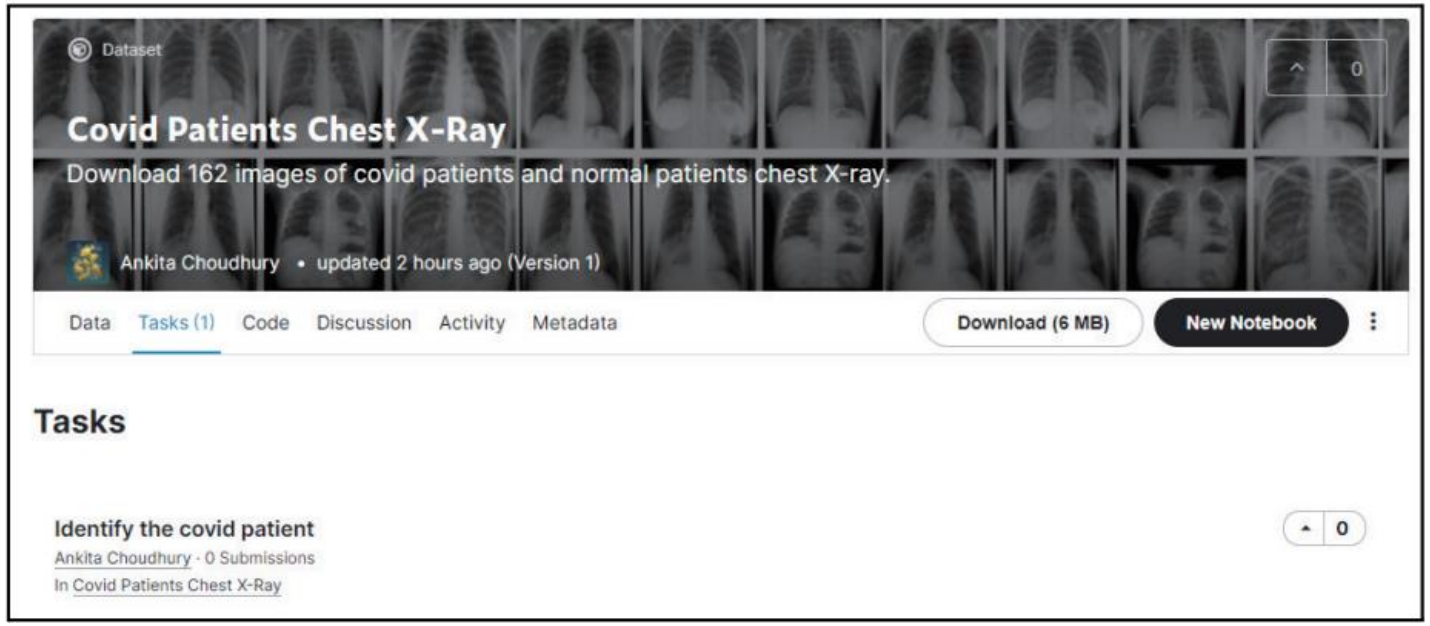

- 지금 이 시간에도 많은 기업이나 정부, 기관에서 데이터를 제공하고 있으며 이 데이터를 바탕으로 훌륭한 분석 결과를 제시하려는 많은 데이터 과학자들이 캐글 생태계를 더욱 더 발전시키고 있음

1.10 데이터 마켓과 열린 데이터

- 지금도 여러 나라의 정부기관과 의료기관 등에서는 많은 데이터를 공개하여 데이터 분석가들이 활용할 수 있도록 하는 **데이터 마켓**data market을 열고 있음
- 모든 사람이 제한 없이 자유롭게 사용하고 재사용할 수 있으며 재배포까지 가능한 데이터를 **열린 데이터**open data라고 함
- 오픈 데이터 핸드북이라는 웹사이트에서는 **열린 데이터의 가장 핵심이 되는 개념**을 다음과 같이 정의

이용성 및 접근	전체 데이터가 이용 가능해야 하며, 합리적인 재생산 비용으로, 가능하면 인터넷에서 다운로드되어야 한다. 데이터는 편리하고 수정 가능한 형태로 제공되어야 한다.
재사용과 재배포	데이터는 서로 다른 데이터와 결합되는 것을 포함하여 재사용과 재배포를 허용하는 조건으로 제공되어야 한다.
보편적 참여	누구나 데이터를 사용, 재사용 및 재배포할 수 있어야 한다. 즉, 활동 분야, 특정한 사람이나 그룹에 대한 차별이 없어야 한다. 예를 들어, '비상업적' 제한 조건은 '상업적' 사용을 제한할 수 있으며, 특정한 목적에 한정된 사용 조건은 허용되지 않는다.

1.10 데이터 마켓과 열린 데이터

데이터에 비례하여 딥러닝 알고리즘은 향상되고 있다

- 최근 눈부신 발전으로 인하여 세상의 주목을 받고 있는 기술인 인공지능은 데이터의 축적과 하드웨어의 발전 그리고 딥러닝 알고리즘의 발전에 의하여 빠르게 성장하고 있음
- 이러한 흐름 중에서 인공지능 알고리즘을 주목하는 것과 함께 **데이터의 확보에 중심을 두자는 흐름** 역시 비중을 차지하고 있음

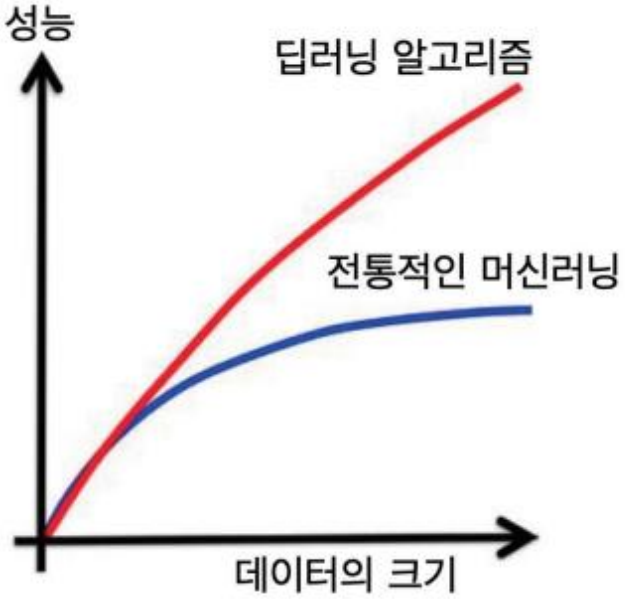

데이터 분석의 단계
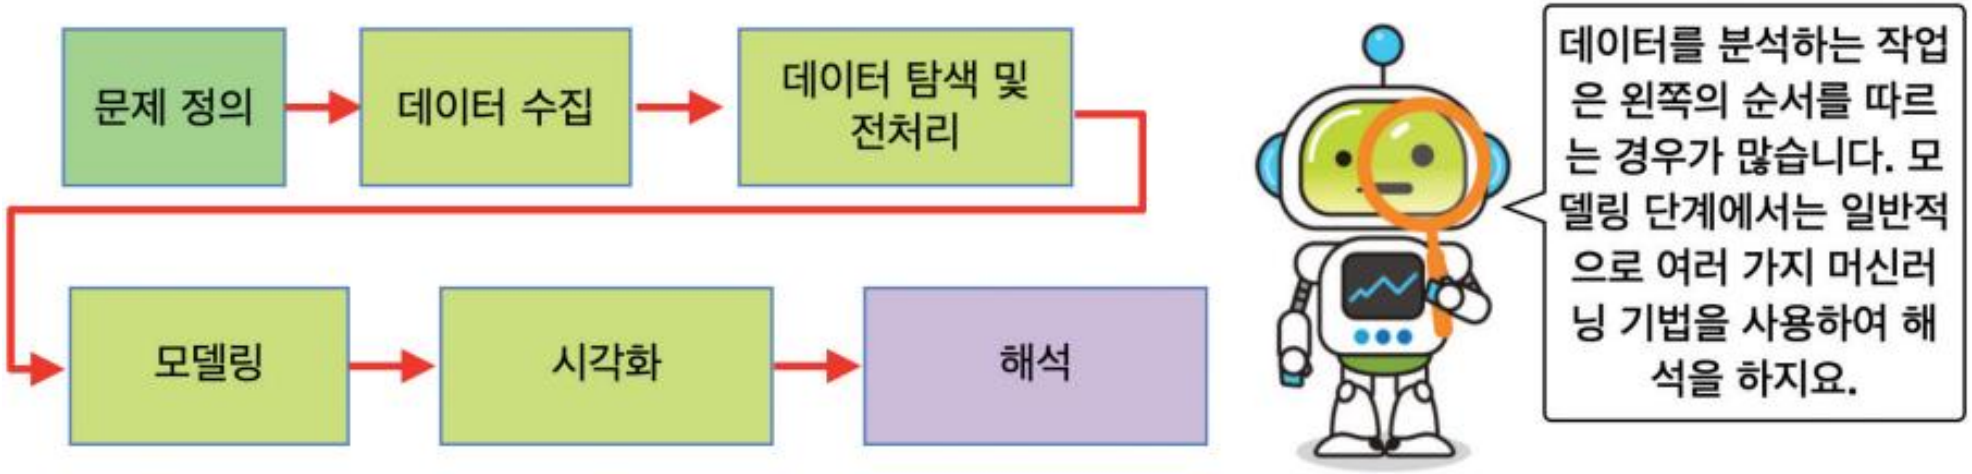
- 업무 활동이나 현업에서 발생하는 원천 데이터는 분석이나 머신러닝에 적합하지 않은 경우가 많음
- 따라서, 인공지능 연구나 개발에 앞서 **원천 데이터로부터 의미 있는 정보를 얻기 위한 작업이 먼저** 이루어져야 함
- 데이터를 분석하는 작업의 순서